Werkzeuge zur Analyse von Bibliotheksdaten

Jakob Voß (VZG) Nico Wagner (DNB)

Bibliothekskongress 2022

2022-05-31

Bibliotheksdaten

Bibliotheksdaten

- *Grundsätzlich* nicht anders als andere Daten
- Aber oft Bibliotheksspezifische Metadatenformate (MARC21, MAB2, PICA, ASEQ, METS/MODS, ONIX…)
- Außerhalb von Bibliotheken irrelevant
  $\Rightarrow$ wenig Support allgemeiner Datenwerkzeuge
- Datenformate altern viel langsamer als Software

Neue Anforderungen an Bibliotheksdaten

- Öffnung und Verknüpfung mit anderen Datenbeständen
- Data Science, Big Data, Visualisierung, Machine-Learning...

Wie mit Bibliotheksdaten umgehen?

Werkzeuge

Werkzeuge für Bibliotheksdaten

1. Allgemeine Datenwerkzeuge (z.B. Excel, OpenRefine)
2. Freie Werkzeuge für bibliothekarische Datenformate
   - Programmierbibliotheken
   - Anwendungsprogramme
3. Integrierte/Interne Werkzeuge (WinIBW, FALCON, BibControl...)

Allgemeine Datenwerkzeuge

Data Science Werkzeugkasten

- Interaktive Notebooks (Jupyter, Observable…)
- Kommandozeile (`grep`, `head`, `sort`…)
- OpenRefine
- GitHub/GitLab
- …

Freie Werkzeuge für Bibliotheksdaten

- Catmandu
- Metafacture
- pica-rs / picadata
- MABLE+/Marcel
- QA Catalogue, Cocoda...

Beispiele

Arbeiten auf der Kommandozeile

- Programme auf der Kommandozeile folgen im Allgemeinen dem EVA-Prinzip

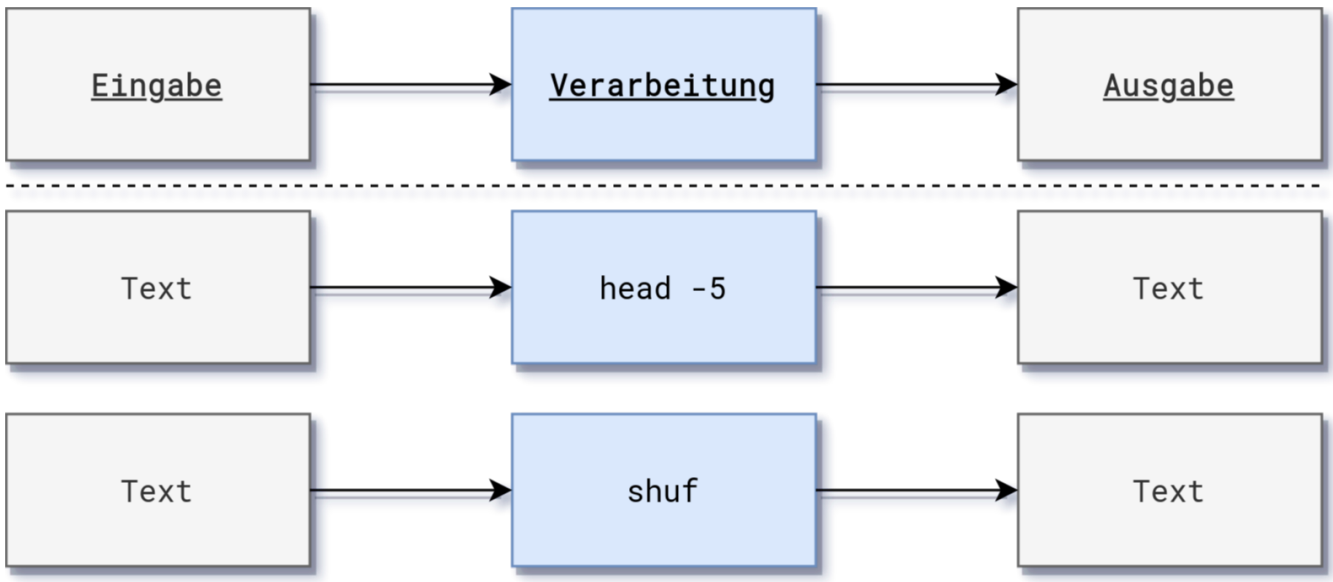

Verkettung von Programmen durch Pipes

- Programme können durch Pipes “|” miteinander verkettet werden

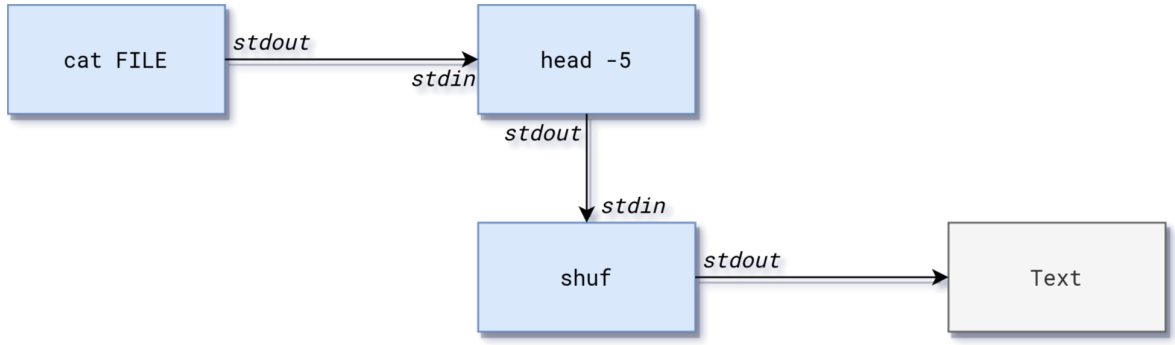


```
$ cat FILE | head -5 | shuf
```

Vorteile

- Integration in Data Science Workflows (Shell-Skripte, Makefiles, Cron-Jobs, DVC)
- Es stehen eine große Anzahl an Standardwerkzeugen zur Verfügung (`head`, `grep`)
- Umfangreiches Literatur- und Fortbildungsangebot

Zählen von PICA-Datensätzen

```
$ wc -l DUMP.dat
1000

$ picadata -f plus DUMP.dat
1000 records
36111 fields

$ pica count DUMP.dat
1000 records
36111 fields
83814 subfields
```

Filtern von PICA-Datensätzen

```
$ pica filter -s \
    "002@.0 =^ 'Tp' && 028A.a == 'Goethe'" \
    | pica count --records
14

$ pica filter -s "002@.0 =^ 'Tp' && 028A.a == 'Goethe'" \
    | picadata -2 -f plain -t json "028A"
[["028A","","d","Friedrich","a","Goethe"]]
[["028A","","d","August","c","von","a","Goethe"]]
```

Tabellieren von Daten

```
$ pica filter -s
    "002@.0 =^ 'Tp' && 028A.a == 'Goethe'" GND.dat \
    | pica select "003@.0, 028A{a, d}"
117749346,Goethe,Friedrich
11854022X,Goethe,August
118540246,Goethe,Katharina Elisabeth
118628011,Goethe,Christiane
...
```

Häufigkeitsverteilung eines Unterfelds

```
$ pica filter -s "002@.0 =^ 'Tg'" GND.dat \
    | pica frequency -l 3 -H "code,count" "042B.a"
code,count
XA-IT,30149
XA-DE-BY,26694
XA-FR,17452
```

Abfrage per SRU-API

```
$ catmandu convert SRU \
    --base http://sru.k10plus.de/opac-de-627 \
    --recordSchema picaxml \
    --parser picaxml \
    --query pica.sgd=590 \
    to PICA --type plain
```

Zwischenfazit

- Werkzeuge lassen sich miteinander kombinieren
  $\Rightarrow$ Stärken der unterschiedlichen Tools ergänzen sich
- Erzeugen von Standardformaten (CSV, JSON)
  $\Rightarrow$ Programmiersprachen und -bibliotheken nutzen
  $\Rightarrow$ Nutzen von allgemeinen Datenwerkzeuge

GND-Dashboard

- Statistische Auswertungen (Datenbasis PICA+)
- Selektion und Transformation der Daten mit *pica-rs*
- Datenaufbereitung und Visualisierung mit Python

Filtern des Gesamtabzugs

- Gesamtabzug der DNB ist ca. 44GB groß
  ⇒ Titeldaten (`title.dat`): 38GB
  ⇒ Normdaten (`gnd.dat`): 5.5GB

```
$ pica filter -s "002@.0 =^ 'T' && !008@.a?" DUMP.dat \
    -o gnd.dat

$ pica filter -s --invert-match "002@.0 =^ 'T'" DUMP.dat \
    -o title.dat
```

GND-Entitäten gesamt

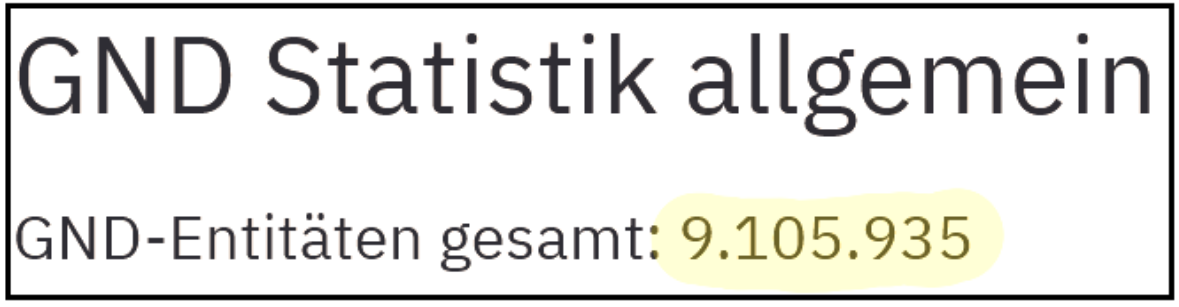


```
$ pica count --records gnd.dat
9.105.935
```

Entitäten und Katalogisierungslevel

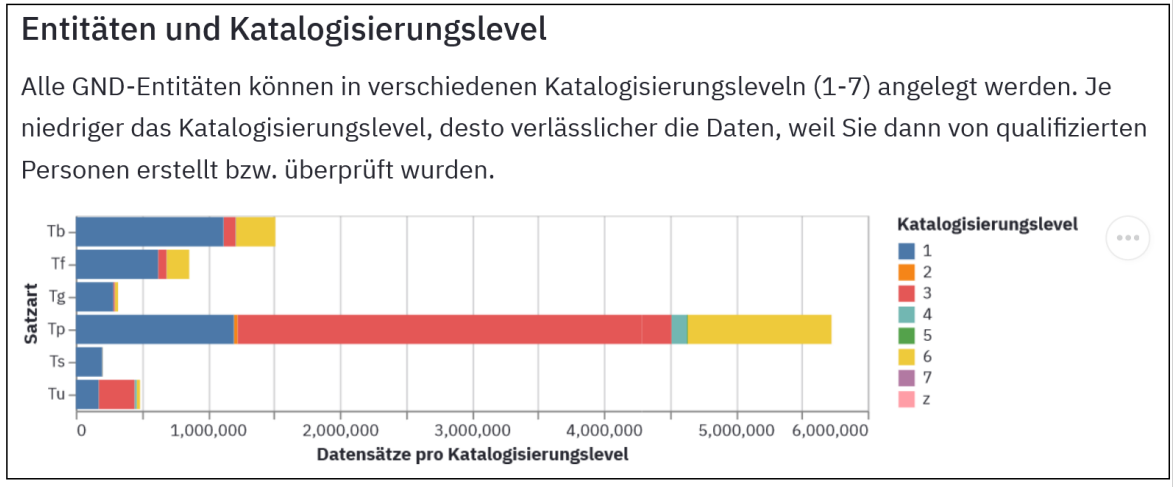


```
$ pica frequency --limit 3 "002@.0" gnd.dat
Tp3,3288170
Tp1,1197189
Tb1,1116481
```

GND-Systematik

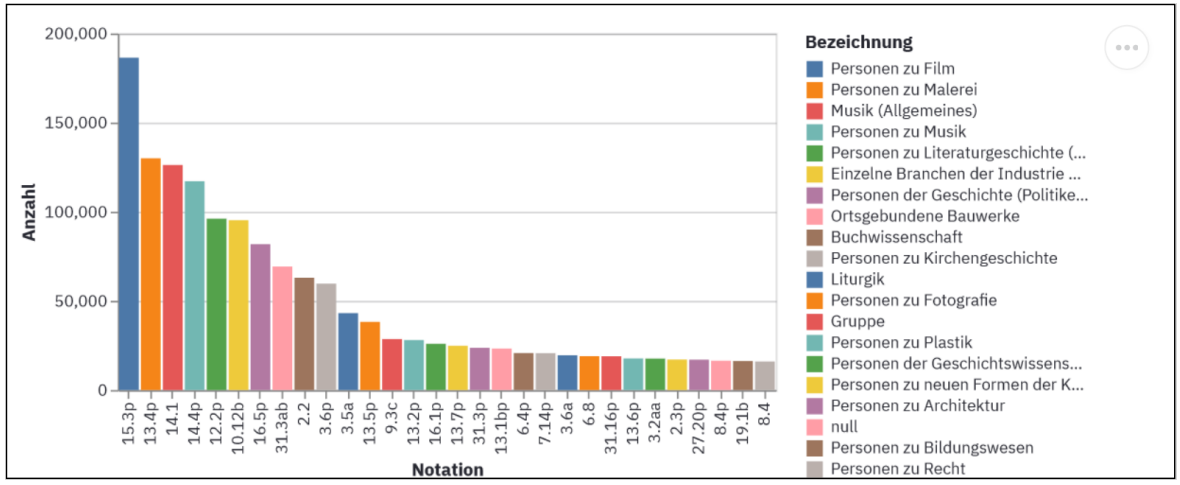


```
$ pica frequency --limit 3 "042A.a" gnd.dat
15.3p,186402
13.4p,129972
14.1,126224
```

GND-Systematik (nur Ts)

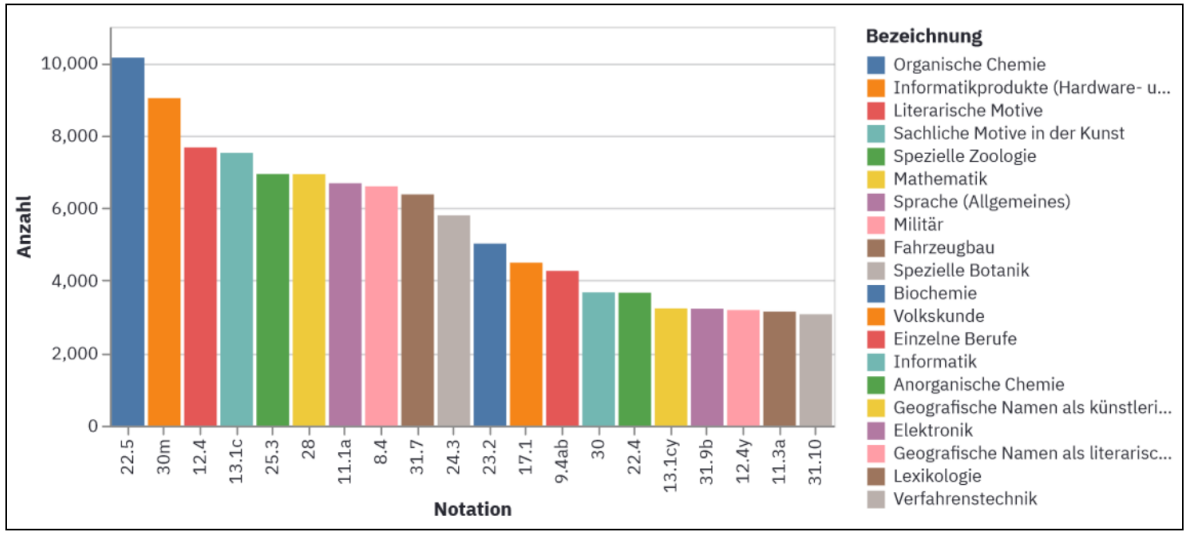


```
$ pica filter "002@.0 =^ 'Ts'" gnd.dat \
    | pica frequency "042A.a"
22.5,10146
30m,9029
12.4,7671
```

Ausblick

Interoperabilität und Standards

- Werkzeuge sollten sich gut mit anderen kombinieren lassen
- Einigung auf gemeinsame Standards (Avram, PICA Path, Fix...)

Herausforderungen

- Dokumentation, Fortbildung, Einarbeitung
- Softwareentwicklung ist Daueraufgabe
- Entwicklung hängt oft an einzelnen Personen
  (Beispiel: MarcEdit, zumal nur Freeware)
- Projektgetriebene Entwicklung selten nachhaltig
  (Beispiel: d:swarm)

Weiterführende Resourcen

- Dokumentation der jeweiligen Programme
- Einführung in die Verarbeitung von PICA-Daten
- Processing MARC with open source tools
- [it-in-bibliotheken]https://it-in-bibliotheken.de (geplant)
- Magnus Pfeffer (2016): Open Source Software zur Verarbeitung und Analyse von Metadaten. Präsentation auf dem 6. Bibliothekskongress. urn:nbn:de:0290-opus4-24490

Guter Rat zum Schluss

Datenverarbeitung ist keine Wissenschaft sondern Handwerk!

Übung macht die Meister*in!